Relatório — Case "Classificação de tópicos"

Luis Paulo · lpmu06@gmail.com · 19/10/2026 · código, dados e saídas brutas de todos os modelos neste repositório

Resultado	Valor
Publicadas	**218 de 359 (60,7%)**, todas no tema de nível 1 (a variante `publicacao_subtema.csv` desce ao subtema em 70 delas)
Para revisão do professor	140, cada uma com a sugestão do revisor automático e o motivo da dúvida
Fora da árvore	1 (imposto estadual; crimes da Lei Geral do Esporte)
Precisão prevista nas publicadas	**0,95**, intervalo de 0,86 a 0,99
Variante sem os temas duplicados	127 publicadas (35,4%), precisão prevista 0,98 (`publicacao_sem_duplicados.csv`)

a) Como pensamos

O problema não é classificar; é saber quando não confiar. Um LLM acerta a maior parte das questões, mas a régua exige 95% de acerto nas publicadas, sem gabarito. Isso é *predição seletiva*: o valor está em separar as questões quase certas das que precisam de um professor e em estimar a própria taxa de erro sem rótulos.

Três leituras da régua guiaram o desenho.

- Só as publicadas contam. Revisar e fora custam cobertura, não precisão.
- Acerto inclui pai e filho do tema do especialista, mas não o irmão. Logo, publicar no tema de nível 1 é correto sempre que o ramo está certo, e o aluno vê a questão ao estudar o tema. Comparamos as duas versões: a entrega (`publicacao.csv`) põe tudo no nível 1; a versão híbrida (`publicacao_subtema.csv`) desce ao subtema em 70 questões, quando o árbitro e o classificador plano concordam com confiança de pelo menos 0,90. Pela régua, a híbrida foi a tentativa que não compensou: mesmas 218 publicadas, risco de irmão a mais e precisão prevista igual, 0,955 nas duas. Publicar no subtema é o que serve a quem estuda "Juiz das Garantias" e não "Inquérito Policial", mas isso exige rótulos do professor para calibrar; fica como trabalho futuro.
- A própria previsão é avaliada, então ela precisa ser conservadora e explicada.

O que testamos, do simples ao caro.

Abordagem	O que aconteceu	Ficou?
Copiar a origem (`assunto_origem` → tema pelo título)	225 questões têm um tema de título igual, mas só 30% caem no mesmo ramo que o consenso dos modelos. "Concurso de Crimes" rotula 43 questões, quase todas sobre outra coisa	Só como voto fraco e diagnóstico
Similaridade de embeddings, 8 modelos (jurídicos brasileiros, portugueses e multilíngues)	Comparar a questão com o nome do tema cria lixeiras: com o Legal-BERTimbau cru, 39% das questões caem num único tema, o mesmo efeito do nosso estudo anterior com andamentos processuais (38%). O melhor modelo, bge-m3, multilíngue e não jurídico, acerta o ramo em 64% e traz o ramo certo entre os 20 primeiros em 93%	Como pré-filtro em produção, não como decisor (anexo)
Enriquecer a taxonomia	337 de 377 descrições eram texto gerado. Um LLM escreveu descrição, palavras-chave, artigos de lei e "não confundir com" para os 351 temas usáveis. Isso melhora todos os embeddings em 10 a 20 pontos	Sim, é a base de tudo
LLM com a árvore inteira no prompt ("plano")	Funciona, mas o prompt tem 211 mil tokens por questão	Sim, como classificador principal
LLM em camadas: 2 estágios (tema, depois subtema) e 3 estágios (grupo, tema, subtema)	Ver o experimento abaixo. 2 estágios fica no mesmo patamar do plano com um prompt 10 vezes menor; 3 estágios perde alguns pontos	2 estágios sim; 3 estágios não
Modelos menores (Sonnet, Haiku)	Em 2 estágios, o Sonnet empata com o Opus; o Haiku fica alguns pontos atrás	Sonnet em 2 estágios é um dos dois votantes
Árbitro (Opus, esforço alto)	Escolhe entre os candidatos de todos, embaralhados, sem saber a maioria. Concorda com o consenso em 99,7% dos casos em que os dois classificadores principais concordam, e baixa a confiança de 0,89 para 0,65 quando eles divergem; só uma vez escolheu fora dos candidatos, o que indica alguma ancoragem	Sim, como filtro e como sugestão para o professor

Abordagem	O que aconteceu	Ficou?
Jev (TypeSafe): probabilidades em vez de texto	Com descrições enriquecidas, sobe de 79,7% para 85,8% de concordância; versão nova, busca em feixe e ordens embaralhadas não ajudam. Calibrado; US$ 1,82 por 5 variantes	Como segunda opinião (anexo)
Buscar a questão em bancos de outros sites	As questões estão na web, mas usar a classificação de um concorrente não nos pareceu correto	Descartado

Experimento de camadas. Em 80 questões sorteadas, cruzamos modelo e método. A tabela mostra o quanto cada um acompanha a maioria dos demais classificadores, sem contar a si mesmo (*leave-one-out*: cada rodada é medida contra a maioria das outras); não é acurácia, é consistência.

Método	Modelo	Acompanha a maioria	Tokens de prompt por questão	US$ por questão, com cache
Plano	Opus 5.5	93,8% (n=80)	211.517	0,054
Plano	Sonnet 5	90,0% (n=80)	211.517	0,050
2 estágios	Opus 5.5	93,8% (n=80)	22.460	0,058
2 estágios	Sonnet 5	93,8% (n=80)	20.790	0,031
2 estágios	Haiku 4.5	90,0% (n=80)	16.525	0,041
3 estágios	Sonnet 5	88,7% (n=80)	13.935	0,039
3 estágios	Haiku 4.5	87,5% (n=40)	10.754	0,051

A segunda camada compensa: o prompt cai dez vezes e a consistência praticamente não cai. A terceira não compensa: cada etapa a mais é uma chance a mais de errar sem volta, e grupos de temas criados à mão não têm fronteiras naturais. Com cache (a parte fixa do prompt, a árvore, fica guardada no provedor e é cobrada a um décimo nas chamadas seguintes), o prompt plano gigante custa quase o mesmo que o de 2 estágios; sem cache, custaria 15 vezes mais. O Haiku sai caro aqui só porque, pelo Claude Code, gera milhares de tokens de raciocínio; pela API, sem raciocínio estendido, custaria uma fração disso. Tabelas completas no anexo.

Becos sem saída. Começamos pelo modelo mais caro com o prompt maior e esgotamos os créditos da OpenAI em 63 questões; a lição é medir custo em cinco questões antes de escalar. A rotulagem humana de uma amostra, que seria o caminho mais sólido para a previsão, não foi possível, então a estimativa é cega. A primeira regra de unanimidade nos ramos confundíveis não tinha efeito com só dois votantes; corrigimos para exigir a concordância de todas as rodadas completas, o mesmo critério para todas as questões. A primeira auditoria viu os votos dos modelos e serviu para escolher os limiares; por isso fizemos uma segunda, cega, só para medir. O Jev como desempate nas questões em revisão reprovou na auditoria cega com controles (26 de 39 promovidas passaram; 39 de 40 publicadas).

Como estimamos a precisão sem gabarito. Nenhum estimador sozinho é confiável, então usamos três, com hipóteses declaradas, e dois descontos para o que nenhum deles vê. Eles não são independentes: os classificadores são todos Claude, e a taxonomia que todos leram foi escrita pelo GPT-5.5, a "outra família".

Estimador	Hipótese	Nas publicadas
Dawid-Skene (modelo que estima a taxa de acerto de cada classificador só pelo padrão de concordâncias) sobre os classificadores e a origem, sem o árbitro	Erros independentes; nas publicadas, onde todos concordam, é um teto	100,0%
Concordância com o GPT-5.5, a única família diferente	Famílias diferentes erram de forma pouco correlacionada; amostra pequena	39 de 39
Auditoria cega, por um agente Claude Opus (mesma família dos classificadores) com contexto limpo, de 50 publicadas sorteadas fora das 60 da primeira auditoria (caderno, instruções)	Quem primeiro argumenta a favor de outro tema acha os erros visíveis; dúvida conta 1/3 de erro. Resultado: 0 erro(s), 1 dúvida(s)	99,3%
Desconto de convenção	O professor pode arquivar diferente de qualquer modelo	−2 pontos nos dois primeiros
Desconto dos gêmeos 67xx	10% de chance de a equipe usar as cópias de título idêntico (46 publicadas expostas) e 5% de usar os nomes de aula "(Parte N)" (45 expostas)	−3,14 pontos em todos

A previsão é a média dos dois estimadores que não supõem independência, ajustados: **0,95**. O intervalo vai do pior limite inferior de 95% (0,86, pelo intervalo de Wilson, adequado a amostras pequenas) ao teto de independência (0,99). Se a equipe tiver rotulado nas cópias, a precisão real cairia para cerca de 78%; nos dois grupos de gêmeos, para 57%. Variando a chance dos gêmeos entre 5% e 25% e o peso de uma dúvida entre 1/3 e 1, o ponto fica entre 0,90 e 0,97. Os limiares finais vieram da primeira auditoria (60 publicadas, com acesso aos votos; 97,9% nas 47 que

seguem publicadas, 3 dúvidas e 0 erros) e da análise de sensibilidade: exigir confiança 0,90 do árbitro em vez de 0,80 corta 11 pontos de cobertura, mas 5 das 9 dúvidas dessa auditoria estavam nessa faixa; subir para 0,95 corta mais 16 pontos sem ganho visível. Por ter escolhido os limiares, essa auditoria não entra na estimativa.

O que foi julgamento, não medida. Descartar a busca em bancos de concorrentes; trocar o modelo mais caro por modelos menores depois de esgotar os créditos; entregar no nível 1; não rotular à mão sem conhecimento jurídico e, por isso, estimar às cegas; e os limiares de 0,90.

b) Diagnóstico: o que atrapalha máquina e humano

Nos dados das questões.

- O texto útil exige as alternativas: 11 enunciados são só "Assinale a alternativa correta".
- A origem é ruidosa: 18 assuntos vazios, 9 disciplinas fora do recorte, nomes de aula como "Ação Penal (Parte 01)" e rótulos trocados. A disciplina de origem diverge da do consenso em 48 questões, quase sempre leis especiais rotuladas como Penal ou Processo Penal.
- HTML cru, `\n` literal e, numa questão, 100 mil caracteres de lixo do Word.

Na árvore.

- **Assuntos com dois endereços.** Prisão aparece em "Teoria Geral das Prisões" e em "Prisões em Espécie"; sentença, em "Sentença Penal" e em "Procedimento Ordinário > Sentença"; ação penal, em Penal e em Processo Penal, cada uma com subtemas de ação pública e privada; juizados, em Legislação Especial e em "Procedimento Sumaríssimo". Foi a principal fonte de dúvida na auditoria.
- **Gêmeos recentes.** 20 temas com ids 67xx, sem descrição nem histórico: 9 copiam, com o mesmo título, temas de outra disciplina (quase todos da Legislação Especial dentro de Penal ou Processo Penal); 11 são nomes de aula, "Teoria da Pena (Parte 1)". Tratamos todos como não utilizáveis e descontamos da previsão a chance de a equipe usá-los, nos dois grupos.
- **Lixeiras.** Temas genéricos acumulavam centenas de questões, como Sistemas e Princípios Processuais Penais (538) e Introdução ao Estudo do Direito Penal (424). Na nossa classificação, só 8 das 359 questões têm um desses temas genéricos como tema central.
- **Descrições.** 337 de 377 eram texto gerado; há erros de grafia ("Crimonológicas", "Estaturo de Idoso", "Comeptência").

Onde está a dificuldade. Medimos pela unanimidade entre classificadores, uma medida de dificuldade que não depende de gabarito (anexo).

Tipo de questão	Unânimes	Publicadas
Múltipla escolha (301)	80%	62%
Certo ou errado (58)	72%	53%
Alternativas sobre institutos diferentes, segundo algum classificador (122)	72%	40%
As demais	82%	71%

Questões multi-tema e de certo ou errado são as mais difíceis: as primeiras não têm tema central, e as segundas trazem uma afirmação curta com pouco contexto. Os pares de ramos que os modelos mais confundem foram: Juizado Especial Criminal × Procedimento Sumaríssimo, Lei de Execução Penal × Teoria da Pena, Competência × Inquérito Policial, Provas em Espécies × Teoria Geral das Provas, Organizações Criminosas × Provas em Espécies. São fronteiras em que até professores divergem, e nelas exigimos unanimidade para publicar.

c) Produção: 50 mil questões por semana

Reclassificar só o que mudou. Rodar as 50 mil toda semana desperdiça dinheiro. O fluxo classifica as importações novas, reclassifica os ramos cuja descrição ou estrutura mudou (a árvore é versionada: cada questão guarda a versão em que foi classificada) e audita uma amostra do resto.

A fila do professor é o gargalo. Com a taxa de revisão deste case (39%), 50 mil questões por semana gerariam 19.500 revisões, cerca de 325 horas a um minuto cada: inviável. Por isso só as importações novas passam pela cascata, e a meta é baixar a taxa para menos de 10% em três meses, atacando as causas da fila de hoje: 28 revisões vêm de classificadores que discordam (segunda família em todas as questões e destilação resolvem parte), 66 de fronteiras entre temas (cada regra de uma linha escrita pelo professor vira instrução para a máquina) 43 de questões sem tema central (decisão de produto: tema mais amplo ou marcação "miscelânea") e 3 de dúvida entre "fora" e um tema. A fila é ordenada: fronteiras primeiro, porque cada resposta vira regra; multi-tema por último. Pela API em lote a resposta leva até 24 h, o que cabe num ciclo semanal.

Cascata, do barato ao caro.

1. **Importação**: limpeza de HTML, deduplicação por hash e extração dos dispositivos citados por regex. A origem entra como metadado, nunca como rótulo.
2. **Pré-filtro por embeddings** (bge-m3 local, custo desprezível): os 20 temas mais parecidos contêm o ramo certo em 93% dos casos e encurtam o prompt.
3. **Classificador principal em 2 estágios** com modelo de porte médio, pela API em lote (metade do preço) e com cache: cerca de US$ 0,016 por questão.
4. **Segunda opinião de outra família** em todas: o Jev, a US$ 0,0013; com probabilidade acima de 0,99 (39% das questões), concordou com a maioria em todas.
5. **Árbitro forte só onde há dúvida**: divergência, confiança baixa ou ramo confundível, cerca de um terço das questões, a US$ 0,025 por chamada em lote: cerca de US$ 0,008.
6. **Publicação** pelas regras deste case; o resto vai para a fila do professor com a sugestão e o motivo.

O total fica em torno de **US$ 0,025 por questão**, ou US$ 1.250 por semana se todas as 50 mil passassem pela cascata; classificando só as novas, é uma fração disso. Os números vêm dos tokens medidos neste case (anexo).

Destilação. Os rótulos confirmados pelo professor treinam um classificador leve sobre embeddings. Com só os 227 rótulos de consenso deste case, ele já reproduz o consenso em 60% dos casos. Com alguns milhares de rótulos revisados, deve assumir os ramos fáceis e virar mais um voto nos demais.

Qualidade contínua.

- Auditoria semanal de 100 publicadas sorteadas, feita por professor, com intervalo de confiança de cerca de ±4 pontos: é o único estimador sem viés.
- Painel com taxa de revisão, concordância entre modelos e distribuição por tema. Um salto num tema sinaliza mudança no banco ou na árvore.
- Reportes de alunos entram como rótulo negativo prioritário: um tema com três ou mais reportes na semana sai da publicação automática até ser revisado. Cada decisão do professor realimenta as descrições dos temas e o classificador destilado.

d) Memo para o professor

Na última página deste documento.

Anexo: modelos, tempo e custo desta execução

Etapa	Modelo	Questões	Tempo de parede
Enriquecimento da taxonomia	GPT-5.5	89 chamadas	8 min
Classificador plano	Opus 5.5	359	18 min
Classificador 2 estágios	Sonnet 5	359	59 min
Classificador 3 estágios	Sonnet 5	359	várias horas, em paralelo com as demais
Árbitro	Opus 5.5, esforço alto	359	4,8 h, em paralelo com as demais
Experimento 2×2 e Haiku	Sonnet 5, Opus 5.5, Haiku 4.5	80	várias horas
GPT-5.5 plano	GPT-5.5	63, até acabar o crédito	8 min

Os modelos Claude foram chamados pelo Claude Code em modo headless, numa assinatura, sem custo marginal; a lentidão veio de dividir a cota da assinatura entre rodadas paralelas. A preço de lista da API, com cache e sem o contexto do Claude Code, o pipeline final (Opus plano, Sonnet 2 estágios e árbitro, este com 19.246 tokens de prompt e 0,041 por questão) custaria US$ 45 para as 359 questões, ou US$ 23 pela API em lote; a soma vem da tabela de métodos do anexo.

Com mais tempo, rotularíamos 100 questões com um professor, rodaríamos um LLM de outra família em todas e perguntaríamos qual tema duplicado a equipe usa.

Memo para o professor

O que encontramos nas 359 questões, o que recomendamos mudar nos temas e do que precisamos de você.

O que fizemos. Vários "leitores" automáticos, de tamanhos e estratégias diferentes, indicaram o tema de cada questão e explicaram por quê. Um leitor mais cuidadoso escolheu entre as sugestões de todos sem saber qual era a maioria. Só publicamos quando todos convergem com segurança, e sempre no tema (não no subtema); o resto vai para a sua fila, com sugestão e motivo.

Publicadas para o aluno	Na sua fila, com sugestão	Sem tema na árvore
218	140	1

Estimamos que entre 86% e 99% das publicadas estão no tema certo, mais provavelmente perto de 96%. Sem gabarito, é uma estimativa; o relatório explica como chegamos a ela.

O que atrapalha a classificação, sua e da máquina.

1. **Temas duplicados.** Lei Maria da Penha, Tráfico de Drogas, Lavagem de Dinheiro, Lei de Execução Penal e outros existem em dois lugares. Quem estuda um não vê as questões do outro. Usamos sempre o tema com histórico; se a equipe usa as cópias recentes, essa é a informação que mais muda o resultado: são 46 das 218 publicadas.
2. **Assuntos com dois endereços.** Prisão está em "Teoria Geral das Prisões" e em "Prisões em Espécie"; ação penal, em Penal e em Processo Penal; juizados, em Legislação Especial e em "Procedimento Sumaríssimo". Foi onde mais tivemos dúvida.
3. **Fronteiras sem regra escrita.** Progressão de regime vai em Execução Penal ou em Teoria da Pena? Uma questão que compara erro de tipo e erro de proibição vai em qual dos dois? Essas convenções são a principal fonte de erro que não conseguimos medir.
4. **Temas com nome de aula.** "Teoria da Pena (Parte 1)", "Competência (Parte 2)" e outros 9 não dizem o que o aluno vai estudar. Não publicamos nada neles; se a equipe os usa, outras 45 publicadas ficam em dúvida.
5. **Temas-lixeira.** "Sistemas e Princípios Processuais Penais" e "Introdução ao Estudo do Direito Penal" acumulavam centenas de questões que não são sobre princípios nem introdução. Na nossa classificação, só 8 questões ficaram em temas desse tipo.
6. **Temas sem descrição.** 337 dos 377 não dizem o que entra e o que não entra, e há erros de grafia nos títulos ("Crimonológicas", "Estaturo de Idoso", "Comeptência"). Escrevemos uma proposta de descrição para cada um, com artigos de lei e "não confundir com", em `data/temas_enriquecidos.json`.
7. **Questões sem tema central.** Em 44 questões, cada alternativa cobra um crime diferente. Hoje vão para a sua fila.

O que recomendamos mudar.

- Manter um único tema por assunto e desativar os temas "(Parte N)" e as cópias.
- Escrever uma regra de uma linha para cada fronteira dos itens 2 e 3. Vale para a máquina e para a consistência entre professores.
- Revisar as descrições propostas, começando pelos temas de fronteira.
- Decidir o destino das questões sem tema central: tema mais amplo ou uma marcação "miscelânea".

Do que precisamos de você.

Pedido	Tempo
Dizer qual dos temas duplicados a equipe usa, e se os temas "(Parte N)" recebem questões	10 minutos
Responder as regras de fronteira dos itens 2 e 3	30 minutos
Revisar a fila de 140 questões, ordenada (fronteiras primeiro, sem tema central por último), cada uma com sugestão e motivo	cerca de 1 minuto por questão, 2 h 20 no total
Validar as descrições dos temas de fronteira	1 hora

Com essas respostas, a próxima rodada publica mais questões com a mesma segurança, e a sua fila fica menor.